ML Canvas — Sustentação de um Modelo de Credit Scoring

Bloco	Conteúdo
Proposta de valor	Reduzir perdas por inadimplência e por recusa indevida, **detectando a degradação silenciosa** do modelo, explicando sua causa e mantendo as decisões auditáveis e conformes à LGPD.
Decisões	Aprovar/negar crédito (score < 0,5 → aprovado); ação sobre o modelo: observar, investigar ou retreinar (política OK/ATENÇÃO/CRÍTICO); rever manualmente decisões contestadas ou de fronteira.
Tarefa de ML	Classificação binária de inadimplência (`default.payment.next.month`), XGBoost tabular com baseline de regressão logística.
Fontes de dados	UCI *Default of Credit Card Clients* (30.000 clientes); janelas de produção **simuladas** por um modelo causal.
Coleta / ingestão	Lote passa por pseudonimização do ID e pelo **contrato Pandera** (8 regras rígidas, 3 suaves); reprovado → quarentena e bloqueio total (exit 2).
Features	21 originais + 4 derivadas; **sem** `sex` , `marriage` e identificadores.
Construção do modelo	Fit só no treino do reference; candidate → **gate (AUC ≥ 0,75)** → champion; versões e linhagem (hash do dataset, git, contrato) no MLflow.
Previsões / uso	Pontuação em lote por janela; *reason codes* por cliente (art. 20).
Avaliação offline	AUC 0,7836 · Gini 0,567 · KS 0,436 · Brier 0,132 (teste do reference); fairness por sexo e idade.
Monitoramento (online)	PSI/KS/Chi²/JS + Evidently por janela; AUC, KS e **gap de calibração**; PSI do score; SLOs: AUC ≥ 0,72, PSI < 0,20, gap de calibração absoluto ≤ 5 p.p., frescor < 7 dias; Grafana, Prometheus, MLflow, logs JSON.
Sustentação / retreino	Política proporcional; retreino contínuo com janelas rotuladas recentes (mesmo gate); runbook em `docs/MONITORING.md` .
Governança / LGPD	Base legal art. 7º, X; minimização; pseudonimização (HMAC-SHA256); retenção executável (dry-run por padrão); RIPD/ROPA; auditoria de vieses.
Riscos	Drift de dados e de conceito (desemprego latente); discriminação por proxy (`education` , `age`); atraso do rótulo; falsos alarmes por PSI sem impacto em desempenho; dependência de versões (Evidently × pandas).
Métricas de sucesso	Zero lote ruim ingerido; M1 (controle) sem alerta; degradação visível em ≤ 1 janela de atraso; recuperação de AUC/calibração após o retreino; DI ≥ 0,8 em todos os atributos auditados.