Sustentação e Confiabilidade de um Modelo de Credit Scoring · Tech Challenge Fase 4

MACHINE LEARNING CANVAS

4 Etapas Concluídas

XGBoost · Pandera · Evidently · MLflow + Prometheus/Grafana · 159 testes

PREDICTION TASK

- **Tipo:** classificação binária — inadimplência no mês seguinte
- **Input:** 25 features cadastrais e financeiras do cliente
- **Output:** P(default) + 3 *reason codes* (fatores que elevam o risco)
- **Desbalanceamento:** ~22% de inadimplentes; métricas de ordenação (AUC, KS) + calibração (Brier)
- **Monitoramento:** drift de dados (P(X)) e de conceito (P(y|X)) por janela

DECISIONS

- Score < 0,5 → crédito aprovado; ≥ 0,5 → negado
- Reason codes informam o titular (LGPD art. 20)
- Decisões contestadas ou de fronteira → revisão humana
- Lote reprovado no contrato → bloqueado e em quarentena
- Política de drift: OK → observar · ATENÇÃO → investigar · CRÍTICO → retreinar + revisão humana

VALUE PROPOSITION

QUEM

Fintech de crédito com modelo em produção sob mudança econômica

OBJETIVO

Detectar e explicar a degradação silenciosa antes que ela vire perda financeira ou decisão injusta

BENEFÍCIO

Lixo não entra no modelo; drift visível por janela; causa da degradação identificada; resposta proporcional (não "retreinar a cada oscilação")

INTERFACE

CLI batch instrumentada · Grafana (11 painéis) · MLflow · painel HTML offline · alertas Prometheus

RESULTADO DEMONSTRADO

Bad batch barrado (exit 2, H1–H7) · M1 de controle sem falso positivo · desemprego latente explica ~94% do gap de calibração em M6 · retreino eleva o AUC de M6 de 0,750 para 0,770

DATA COLLECTION

- Download reprodutível via `scripts/download_data.py` (ucimlrepo, fallback OpenML)
- Split único 60/40 (seed 42, estratificado): reference 18.000 · pool 12.000
- ID pseudonimizado (HMAC-SHA256) na ingestão
- Contrato Pandera: 8 regras rígidas + 3 suaves, lote atômico
- Janelas M1..M6 de 1.200 clientes, também validadas antes do scoring

DATA SOURCES

- UCI *Default of Credit Card Clients* (id=350; Yeh & Lien, 2009)
- 30.000 clientes · 23 variáveis · Taiwan, 2005
- Limite, faturas e pagamentos de 6 meses, status de atraso, idade, escolaridade, sexo, estado civil
- **Produção simulada:** SCM com inflação, aperto de crédito, desemprego (latente) e perfil jovem

OFFLINE EVALUATION — TEST SET: 3.600 CLIENTES (20% DO REFERENCE)

0,7836 AUC-ROC	**0,5671** Gini	**0,4355** KS de separação	**0,1321** Brier
0,7021 Precision	**0,3819** Recall	**0,7828** AUC com sex/marriage	**0,980** Disparate Impact (sexo)

MAKING PREDICTIONS

- Batch por janela: `python -m src.pipeline.cli monitor`
- Fluxo: contrato → score → drift → performance → política → alertas
- Tempo real medido: monitor das 6 janelas em 20,1 s (com Evidently e MLflow)
- Rótulo revelado "com atraso" para medir concept drift
- Métricas empurradas ao Pushgateway por task

BUILDING MODELS

- **Produção:** XGBoost (300 árvores, max_depth 4, lr 0,05)
- **Baseline (Factory):** regressão logística balanceada
- Treino em `models/candidate/`; gate AUC ≥ 0,75 → champion + alias MLflow
- Persistência em JSON nativo (sem pickle)
- Retreino contínuo: reference + janelas rotuladas recentes, mesmo gate

FEATURES

Originais (21) e derivadas (4)

- limit_bal · education · age · pay_0, pay_2..pay_6 · bill_amt1..6 · pay_amt1..6
- utilization = bill_amt1 / limit_bal · payment_ratio = pay_amt1 / bill_amt1
- max_delay = maior atraso · months_delayed = meses com atraso

Mais influentes (média |SHAP| no teste)

- max_delay (0,560) · pay_0 (0,262) · utilization (0,175)
- pay_amt2 (0,126) · bill_amt1 (0,119) · months_delayed (0,103)
- Mais degradadas em M6 (PSI): utilization 0,62 · pay_2 0,33 · limit_bal 0,31

Excluídas por governança (LGPD)

- client_id → só como client_hash (identificador, fora do modelo)
- sex e marriage → risco discriminatório; só em área segregada para auditoria
- education e age → usadas, com monitoramento de proxy e fairness

■ **CRÍTICOS** PSI ≥ 0,20 · AUC < 0,72 · contrato violado · task com falha · gap de calibração > 5 p.p. ▲ **WARNINGS** PSI 0,10–0,20 · queda de AUC 0,02–0,05 · regras suaves S1–S3 · sem sucesso há 7 dias

◆ **MÉTRICAS** credit_feature_psi, credit_model_auc, credit_calibration_gap, credit_contract_status, credit_task_status (Prometheus)

✓ **QUALIDADE** 159 testes · 98% cobertura · ruff e mypy sem erros · CI lint → test → contract-gate → drift-demo