Model Card — Credit Scoring (XGBoost)

> **Uso restrito:** modelo didático, treinado em dados de Taiwan de 2005 e com tempo simulado. **Não usar em decisão de crédito real.**

Detalhes do modelo

Nome / registro	`credit-scoring` (MLflow Model Registry, alias `champion`)
Tipo	`XGBClassifier` — 300 árvores, `max_depth=4`, `learning_rate=0,05`, `eval_metric=auc`, `random_state=42`
Baseline de comparação	Regressão logística (`StandardScaler`, `class_weight="balanced"`) — via Factory
Tarefa	classificação binária: P(default no próximo mês | X)
Entrada	25 features: 21 originais (`limit_bal`, `education`, `age`, `pay_0`, `pay_2..6`, `bill_amt1..6`, `pay_amt1..6`) + 4 derivadas (`utilization`, `payment_ratio`, `max_delay`, `months_delayed`)
Não usa	`client_id` / `client_hash`, **`sex`, `marriage`** (minimização e não discriminação)
Formato	JSON nativo do XGBoost + `metadata.json` (sem pickle); MLflow com *signature* e *input_example*
Versões	xgboost 3.2.0, scikit-learn 1.9.1, pandas 2.3.3
Contrato de dados	v1.0.0

Dados

Default of Credit Card Clients (UCI id=350; Yeh & Lien, 2009): 30.000 clientes, ~22% de inadimplência. Split único e estratificado (seed 42): **reference 60% (18.000)** → treino 80% / teste 20% (3.600); **pool de produção 40% (12.000)** → janelas simuladas. Códigos não documentados (`education` 0, 5, 6; `marriage` 0) são remapeados para "outros" na limpeza.

Métricas (teste do reference, 3.600 clientes, threshold 0,5 — `models/metrics_train.json`)

AUC	Gini	KS	F1	Precision	Recall	Brier
0,7836	0,5671	0,4355	0,4947	0,7021	0,3819	0,1321

Confusão: TN 2675 · FP 129 · FN 492 · TP 304. O recall (0,38) é baixo no threshold 0,5: a alternativa por custo (threshold menor) deve ser definida pela política de risco. **Gate de promoção:** AUC ≥ 0,75. Com `sex` / `marriage` o AUC seria 0,7828 — a exclusão não custa desempenho.

Desempenho sob drift (janelas simuladas, 1.200 linhas)

Janela	AUC	Brier	Gap de calibração	Severidade
M1 (controle)	0,7746	0,1394	−0,0171	OK
M3	0,7868	0,1412	+0,0192	ATENÇÃO
M6	0,7501	0,1733	−0,0426	ATENÇÃO

Após o retreino com M4+M5, em M6: AUC 0,7702 · Brier 0,1685 · gap −0,0374.

Fairness (regra dos 80%, aprovado = score < 0,5)

Conjunto	Atributo	Disparate Impact	Dif. de oportunidade
reference (teste)	sexo	0,980	0,016
reference (teste)	faixa etária	0,877	0,042
M6	sexo	0,998	0,017
M6	faixa etária	0,864	0,043

Sem violação da regra dos 80%, mas **menores de 25 anos** têm a menor taxa de aprovação (0,802; 0,770 em M6). Em M6 o AUC por sexo diverge (F 0,765 × M 0,725). Monitorar continuamente.

Explicabilidade

Reason codes: os 3 principais fatores que elevam o risco de cada cliente, via contribuições SHAP nativas do XGBoost (`pred_contribs`); teste garante soma das contribuições + bias = margem prevista (LGPD art. 20).

Limitações e uso responsável

- Dataset de Taiwan (2005), sem renda; o **tempo é simulado** e o rótulo é revelado sem atraso.
- `education` e `age` podem atuar como proxies socioeconômicos/geracionais.
- Performance degrada com drift; o AUC sozinho é sinal ruidoso — acompanhar a **calibração** e o PSI.
- Concept drift por variável latente (ex.: desemprego) não é visível em P(X); exige rótulos e, possivelmente, um proxy sob avaliação de minimização.
- Decisões contestadas ou na fronteira devem passar por **revisão humana** (art. 20).
- Retreino sempre via mesmo gate e promoção; versões aposentadas guardadas por 5 anos para auditoria.