VISÃO GERAL · PERFORMANCE · ARQUITETURA · FEATURES · LIMITAÇÕES · VALIDAÇÃO · DATASET · DEPLOYMENT · MONITORAMENTO · GOVERNANÇA

Model Card — Credit Scoring

Classificador binário de inadimplência (default no mês seguinte) treinado sobre o *Default of Credit Card Clients* (UCI), cercado por uma camada de sustentação: contrato de dados, detecção de drift, observabilidade, análise causal e governança LGPD.

Ciclo de sustentação validado · **v1.0.0 · XGBoost** · **xgboost 3.2.0** · **Pandera 0.35 · Evidently 0.7.23** · **MLflow 3.18 · Prometheus · Grafana** · **Didático — não usar em crédito real**

30.000
CLIENTES
reference 18.000 · pool 12.000

25
FEATURES
21 originais + 4 derivadas

0,7836
AUC-ROC
Gini 0,567

0,4355
KS DE SEPARAÇÃO
padrão de crédito

6
JANELAS SIMULADAS
M1 controle · 1.200 linhas

159
TESTES
cobertura 98%

1. Visão Geral do Modelo

Objetivo: estimar P(default = 1 | X) para cada cliente e apoiar a decisão de crédito (score < 0,5 → aprovado), com a explicação dos principais fatores de risco de cada decisão (*reason codes*).

Contexto de negócio
Uma fintech suspeita de **degradação silenciosa** do seu modelo de crédito após mudanças econômicas (inflação, aperto de crédito, desemprego, novos perfis): o pipeline "roda verde", mas as decisões pioram. O foco do projeto é a camada de sustentação e confiabilidade — o modelo é intencionalmente simples.

INDICADOR	VALOR
Amostras totais	30.000 clientes · ~22% de inadimplência
Separação referência × produção	reference 60% (18.000) · pool de produção 40% (12.000) — split único, estratificado
Split interno do reference	treino 80% (14.400) / teste 20% (3.600), estratificado
Threshold de decisão	0,5 (configurável em `DECISION_THRESHOLD`)
Gate de promoção	AUC ≥ `MIN_AUC` = 0,75 — treino grava em `models/candidate/`; só a promoção publica o champion
Seed de reprodutibilidade	42 (split, modelo e simulação)
Registro	`credit-scoring` no MLflow Model Registry, alias `champion` (aliases no lugar de *stages*, deprecados)
Data do último treino (referência)	2026-11-07 — `models/metrics_train.json`

2. Performance do Modelo

Métricas no conjunto de teste do reference (3.600 clientes, threshold 0,5) — geradas por `src/models/evaluate.py` e reproduzíveis via `make train` (fonte: `models/metrics_train.json`).

MÉTRICA	VALOR	LEITURA
AUC-ROC	**0,7836**	**capacidade de ordenar bons e maus pagadores**
Gini (2·AUC − 1)	0,5671	régua usual do mercado de crédito
KS de separação	0,4355	máx(TPR − FPR)
F1	0,4947	classe positiva (inadimplente)
Precision	0,7021	dos negados, 70% de fato inadimpliriam
Recall	0,3819	baixo no threshold 0,5
Brier score	0,1321	calibração das probabilidades

MATRIZ DE CONFUSÃO	PREVISTO: ADIMPLENTE	PREVISTO: INADIMPLENTE
Real: adimplente	2.675 (TN)	129 (FP)
Real: inadimplente	492 (FN)	304 (TP)

Leitura honesta do resultado
AUC 0,78 está na faixa esperada para este dataset. O recall de 0,38 mostra que, no threshold 0,5, a maior parte dos inadimplentes é aprovada: a escolha do threshold deve vir de uma política de custo (perda por inadimplência × receita perdida), não do default. O critério de avaliação deste projeto é o ciclo de sustentação, não o estado da arte.

Performance sob drift (janelas simuladas de 1.200 clientes)

JANELA	AUC	QUEDA VS. BASELINE	BRIER	GAP DE CALIBRAÇÃO	POLÍTICA
M1 (controle)	0,7746	0,0089	0,1394	−1,71 p.p.	OK
M2	0,7718	0,0118	0,1460	−0,56 p.p.	ATENÇÃO
M3	0,7868	−0,0032	0,1412	+1,92 p.p.	ATENÇÃO
M4	0,7443	0,0393	0,1570	−0,24 p.p.	ATENÇÃO
M5	0,7679	0,0157	0,1646	−2,58 p.p.	ATENÇÃO
M6	0,7501	0,0334	0,1733	−4,26 p.p.	ATENÇÃO
M6 após retreino (M4+M5)	**0,7702**	**—**	**0,1685**	**−3,74 p.p.**	**recuperação parcial**

O sinal de concept drift está na calibração, não no AUC
Em janelas de 1.200 clientes o AUC oscila na ordem de 0,01–0,02 (M3 ficou acima do baseline). O Brier sobe de 0,139 (M1) para 0,173 (M6) e o gap de calibração chega a −4,3 p.p.: o modelo passa a prever menos inadimplência do que ocorre. A política não chegou a CRÍTICO (queda de AUC < 0,05 e gap < 5 p.p.); os parâmetros do cenário foram mantidos como especificados.

3. Arquitetura do Modelo

Do lote bruto ao score explicado

Lote CSV / janela com client_id → **HMAC** client_id → client_hash → **Contrato** Pandera H1–H8 · S1–S3 → **Features** limpeza + 4 derivadas → **XGBoost** 300 árvores max_depth 4 → **Score** P(default) + 3 reason codes

PARÂMETRO	VALOR
Classificador de produção	XGBClassifier (n_estimators=300, max_depth=4, learning_rate=0,05, eval_metric="auc", random_state=42)
Baseline de comparação (Factory)	LogisticRegression (StandardScaler + class_weight="balanced") — não promovido
Pré-processamento	remapeia códigos não documentados (education 0/5/6 → 4; marriage 0 → 3) e deriva utilization, payment_ratio, max_delay, months_delayed — determinístico, sem estatística aprendida
Fit	somente no treino do reference (sem vazamento)
Persistência	`model.json` (formato nativo do XGBoost) + `metadata.json` — sem pickle entre ambientes
Rastreamento	MLflow: params, métricas, signature + input_example, matriz de confusão, tags de linhagem (SHA-256 do reference, SHA do git, versão do contrato)
Explicabilidade	contribuições SHAP nativas do XGBoost (`pred_contribs`); teste garante soma das contribuições + bias = margem prevista

O gate protege a produção
Lição da Fase 3: o treino escrevia direto no diretório servido, e um modelo reprovado já tinha substituído o oficial. Aqui o treino grava em `models/candidate/`; só a promoção, após o gate, copia para `models/champion/` e move o alias. Um teste garante que um candidato reprovado não altera o champion.

4. Features Mais Influentes

Média do |SHAP| por feature no teste do reference (3.600 clientes) e frequência com que cada feature aparece entre os 3 *reason codes* de um cliente. Proxy de influência no modelo, não importância causal.

FEATURE	MÉDIA |SHAP|
max_delay	0,560
pay_0	0,262
utilization	0,175
pay_amt2	0,126
bill_amt1	0,119
months_delayed	0,103
limit_bal	0,097
pay_amt1	0,093

REASON CODE	% DOS CLIENTES
max_delay	29,3%
pay_amt2	27,9%
bill_amt1	26,4%
utilization	22,9%
pay_amt1	21,1%
limit_bal	18,6%

Leitura de domínio
O histórico de atraso (`max_delay`, `pay_0`, `months_delayed`) domina o risco, seguido do comprometimento do limite (`utilization`) e dos valores pagos. Duas derivadas criadas no projeto (`max_delay` e `utilization`) estão entre as três mais influentes.

Minimização sem custo de desempenho
`sex` e `marriage` estão fora das features. Medido no mesmo split: AUC sem eles 0,7836 × com eles 0,7828 — excluí-los não custa desempenho (princípio da funcionalidade total).

5. Limitações e Riscos

1. Dataset e tempo simulados Risco crítico (uso real)

Dados de Taiwan de 2005, sem renda e sem data por cliente. O "tempo" é simulado em janelas por um modelo causal com mecanismos hipotéticos, e o rótulo é revelado sem atraso (na vida real a inadimplência chega meses depois). **Não usar em decisão de crédito real.**

2. Concept drift por variável latente Risco alto

O choque de desemprego (não observado) explica ~94% do gap de calibração em M6 e não aparece em P(X): o diagnóstico observacional erra o sinal. Detectar exige rótulos e, possivelmente, um proxy da variável latente (dado de emprego), sujeito à avaliação de minimização da LGPD.

3. Proxies de atributos sensíveis Risco médio

`education` pode atuar como proxy socioeconômico e `age` diferencia grupos: menores de 25 anos têm a menor taxa de aprovação (0,802 no teste; 0,770 em M6), ainda dentro da regra dos 80%.

4. Recall baixo no threshold padrão Risco médio

Recall de 0,38 em 0,5: o threshold deve ser definido pela política de risco e custo do negócio.

5. AUC ruidoso em janelas pequenas Mitigado

A política combina magnitude (PSI), desempenho (AUC) e calibração (gap), e o monitoramento acompanha também o Brier, para não depender de um único sinal ruidoso.

6. Portabilidade e versões de dependências Resolvido

Modelo em JSON nativo (sem pickle, lição 13.3 da Fase 3) e versões fixadas no `poetry.lock`. Encontrado na validação: o Evidently 0.7.23 não importa com pandas 3.1, embora o resolver do Poetry aceite a combinação — fixado `pandas<3`.

6. Validação e Testes

159
TESTES PASSANDO
sem o dataset real

98%
COBERTURA (SRC/)
pytest --cov=src

5
MARKERS
smoke · schema · unit · integration · requires_data

SUÍTE	ARQUIVO	TESTES	FOCO
Integrações de risco	test_smoke_integrations.py	4	APIs reais de Evidently 0.7, Pandera e MLflow 3 nas versões fixadas
Config + Logger	test_config.py, test_logger.py	11	Settings/.env, YAML inválido falha, log JSON, ausência de print() em src/, logs da suíte isolados
Dados	test_data.py	11	normalização das colunas UCI e OpenML, split estratificado e disjunto, gerador sintético
Contrato	test_contracts.py	33	cada regra rígida isolada, lazy, regras suaves, quarentena, exit code 2
Privacidade	test_privacy.py	14	HMAC, minimização, features ∩ PII = ∅, retenção com dry-run
Modelo	test_models.py	14	métricas em caso fixo, gate reprovado não altera o champion, reason codes
Drift	test_drift.py	29	PSI/KS/Chi²/JS, SCM, controle M1 sem falso positivo, controles negativos, política
Causal + fairness	test_causal_fairness.py	10	mecanismo único identificado como dominante, DI e Equal Opportunity em casos fixos
Observabilidade	test_observability.py, test_monitoring_config.py	21	métricas e cardinalidade, Observer, Template Method, dashboard e regras de alerta
Ponta a ponta	test_pipeline_e2e.py	12	`demo --synthetic` completo, exit codes, logs sem dado pessoal

CI isolado do dataset real
Nenhum teste baixa o dataset: um gerador sintético com o mesmo schema (`src/data/synthetic.py`) alimenta os testes e a demo do CI — dado real nunca entra no CI (medida de privacidade).

7. Dataset

PROPRIEDADE	VALOR
Fonte	Default of Credit Card Clients — UCI Machine Learning Repository, id=350 (Yeh & Lien, 2009)
Download	`scripts/download_data.py` (ucimlrepo, com fallback OpenML) → `data/raw/credit_default.csv`
Formato recebido	features `X1..X23` + alvo `Y` + ID à parte; normalizado para nomes padronizados (o original pula `pay_1`; mantido)
Amostras	30.000 clientes · 23 variáveis · ~22% de inadimplência
Por que este dataset	volume para janelas de produção; variáveis financeiras com sentido econômico para o drift; atributos pessoais reais para o plano LGPD e a auditoria de vieses; problemas de qualidade reais (códigos não documentados)
Por que não o German Credit	1.000 linhas — não atende o mínimo de 5.000 do enunciado
Qualidade	reference e pool aprovados no contrato, sem violações nem avisos suaves

8. Deployment

Decisão arquitetural: scoring em lote por janela

✓ Arquitetura escolhida: pipeline batch instrumentado
A concessão é avaliada por lotes (janelas mensais) e o valor do projeto está em validar cada lote, monitorar e reagir. Por isso o pipeline é uma CLI batch de Tasks instrumentadas, e as métricas vão ao Prometheus via Pushgateway (o padrão para jobs batch).

CRITÉRIO	BATCH POR JANELA (ESCOLHIDO)	API REAL-TIME
Validação de dados	contrato atômico por lote, com quarentena	registro a registro, sem visão do lote
Detecção de drift	natural: compara a janela inteira com o reference	exige janelamento adicional
Rótulos	chegam por janela (com atraso, na vida real)	mesmo problema
Métricas	Pushgateway (job batch)	scrape direto do serviço

Infraestrutura

COMPONENTE	TECNOLOGIA	DETALHE
Pipeline	CLI Python (`python -m src.pipeline.cli`)	prepare · validate · train · simulate · monitor · causal · fairness · report · retrain · all · demo; exit codes 0/1/2/3
Rastreamento	MLflow 3.18 (servidor, SQLite em volume)	experimentos credit-training, data-validation, drift-monitoring; Model Registry com aliases
Métricas e alertas	Pushgateway v1.9 → Prometheus v2.53 → Grafana 11.1	12 métricas `credit_*`, 5 regras de alerta (validadas com promtool), 11 painéis provisionados
Stack local	docker-compose	imagens com versão fixada (sem :latest)
CI	GitHub Actions	lint · test · contract-gate (afirma exit 2) · drift-demo (publica reports/)

Checklist de entrega

✓ Concluído
Modelo treinado no dataset real e promovido pelo gate · contrato bloqueando o lote corrompido · drift simulado e detectado (M1 sem falso positivo) · stack de observabilidade de pé com alertas · análise causal · fairness · retreino com recuperação · 159 testes, 98% de cobertura · ruff e mypy sem erros

⏳ Pendente
Push para o GitHub (para o workflow do Actions rodar de fato e o badge funcionar) · Vídeo STAR de demonstração

9. Monitoramento

Detalhamento completo em `docs/MONITORING.md`. Resumo:

MÉTRICA	MÉTODO	THRESHOLD / SLO	FREQUÊNCIA
Drift de dados	PSI por feature (+ KS/Chi² para significância), `credit_feature_psi`	moderado ≥ 0,10 · severo ≥ 0,20 (alerta DataDriftCritical)	por janela
Desempenho	AUC com rótulos, `credit_model_auc`	SLO AUC ≥ 0,72 (alerta ModelAUCBelowSLO)	por janela rotulada
Concept drift	gap de calibração, `credit_calibration_gap`	|gap| > 5 p.p. → CRÍTICO	por janela rotulada
Qualidade de dados	contrato, `credit_contract_status` e `credit_rows_rejected_total`	lote reprovado → 0 linhas ingeridas (alerta ContractViolation)	por lote
Saúde do pipeline	status, duração, memória e último sucesso por task	falha → PipelineTaskFailed · sem sucesso > 7 dias → PipelineStale	por execução

10. Governança e Ética (LGPD)

PRINCÍPIO	IMPLEMENTAÇÃO	STATUS
Base legal	art. 7º, X — proteção do crédito (complementar: art. 7º, V); consentimento descartado pela assimetria de poder e revogabilidade	OK
Minimização e não discriminação	`sex` e `marriage` fora das features (art. 6º, III e IX), mantidos só em área segregada para auditoria	OK
Pseudonimização	HMAC-SHA256 do `client_id` com chave no `.env`; o ID cru nunca sai da ingestão (dado pseudonimizado continua sendo dado pessoal)	OK
Revisão de decisão automatizada (art. 20)	3 reason codes por cliente + fluxo de revisão humana	OK
Retenção	`scripts/apply_retention.py` com prazos do `.env`, dry-run por padrão	OK
Logs e relatórios	sem dados pessoais (teste automatizado); violações só com hash curto	OK
Uso pretendido	demonstração do ciclo de sustentação — não é sistema de crédito real	Uso restrito

Auditoria de vieses (regra dos 80%, aprovado = score < 0,5)

CONJUNTO	ATRIBUTO	TAXAS DE APROVAÇÃO	DISPARATE IMPACT	DIF. DE OPORTUNIDADE
Reference (teste)	Sexo	F 0,887 · M 0,869	0,980	0,016
Reference (teste)	Faixa etária	<25: 0,802 · 25–40: 0,890 · 40–60: 0,881 · >60: 0,914	0,877	0,042
M6	Sexo	F 0,866 · M 0,864	0,998	0,017
M6	Faixa etária	<25: 0,770 · 25–40: 0,891 · 40–60: 0,851	0,864	0,043

Sem violação, mas com ponto de atenção
Nenhum grupo viola a regra dos 80%, mas os menores de 25 anos têm a menor aprovação, e o drift a reduz (DI de 0,877 para 0,864). Em M6 o AUC por sexo também diverge (F 0,765 × M 0,725). Mitigação: revisar features correlatas à idade, threshold por política, Disparate Impact como métrica contínua e revisão humana nos casos de fronteira.